



Instituto Tecnológico de Estudios Superiores de Monterrey

Modelación de sistemas con ecuaciones diferenciales

Grupo 301

PINNs y Sistemas no-lineales de EDOs

Reto Final

Integrantes:

Rodrigo Martínez Escalante | A00838495

Luis Roberto Campos Solís | A00838686

Mariana Villarreal R. Vela | A01722821

Santiago Rodriguez | A01198752

Karla Sofía Cantú Zendejas | A01285550

Diego Armando Mijares | A01722421

Fecha de entrega:

1 de diciembre de 2024

Docentes:

Sofía Salinas Obregon

Daniel Otero Fadul

Resumen

Este reporte aborda el modelado de la angiogénesis, un proceso clave en el crecimiento tumoral, mediante sistemas de ecuaciones diferenciales ordinarias (EDOs) no lineales. Se emplearon métodos numéricos como Euler y Runge-Kutta 4 (RK4), y redes neuronales físicamente informadas (PINNs) para comparar precisión y eficiencia. Los resultados muestran que RK4 y Euler ofrecen mayor estabilidad numérica, mientras que las PINNs capturan dinámicas biológicas más realistas, aunque menos estables. La elección del método depende de priorizar estabilidad o realismo biológico, destacando la relevancia de modelar fenómenos complejos para optimizar tratamientos contra el cáncer.

Descripción del problema planteado

El cáncer es una de las causas principales de muerte en el mundo. En 2022, hubo 20 millones de casos nuevos y 9,7 millones de muertes por cáncer en el mundo. Esta enfermedad se caracteriza por el crecimiento descontrolado de células. Existe un proceso llamado angiogénesis mediante el cual se forman nuevos vasos sanguíneos a partir de los existentes. Es fundamental para procesos fisiológicos normales (por ejemplo la cicatrización de las heridas) pero también permite a los tumores obtener nutrientes y oxígeno para crecer, además de facilitar la formación de metástasis, permitiendo que las células cancerosas se propaguen a diferentes órganos.

Al ser un proceso clave para el crecimiento y la propagación de los tumores, modelar el comportamiento de la angiogénesis es fundamental durante el tratamiento del paciente. Si logramos comprender y predecir la dinámica que existe entre el crecimiento del tumor y la formación de nuevos vasos sanguíneos nos permitirá elegir un tratamiento adecuado para limitar la expansión del tumor.

En este reporte, se busca modelar el proceso de angiogénesis utilizando un sistema de ecuaciones diferenciales ordinarias (EDOs) no lineales. Para resolver este sistema haremos una comparación entre distintas soluciones: utilizando métodos numéricos tradicionales y mediante una red neuronal físicamente informada (PINN) para comparar la precisión y eficiencia de cada uno.

Modelo e ideas implementadas

Modelo matemático (SEDO)

Un sistema de ecuaciones diferenciales ordinarias es un conjunto de ecuaciones diferenciales ordinarias que se relacionan entre sí. Estas son útiles para modelar fenómenos en los cuales variables dependientes cambian simultáneamente en función de una o más variables. En esta investigación, se basa el modelaje en la ecuación número 15 del artículo “*A Review of Mathematical Models for Tumor Dynamics and Treatment Resistance Evolution of Solid Tumors*” (Ouerdani, A., Struemper, H., Suttle, A. B., Ouellet, D., & Ribba, B. 2015), el cual plantea el proceso biológico de la angiogénesis en el crecimiento de tumores. La ecuación es la siguiente:

$$\frac{dT}{dt} = k_g * T * (1 - \frac{T}{E})$$

$$\frac{dE}{dt} = k_1 * T^{1/2}$$

Donde:

- T representa la carga tumoral
- k_g es la constante de crecimiento del tumor, en este caso se aproximó a ≈ 0.015
- E es la capacidad máxima de los vasos sanguíneos para soportar el crecimiento del tumor
- k_1 es la constante de crecimiento de la capacidad de soporte vascular, en este caso se aproximó a ≈ 0.15
- $T(0) = 20$
- $E(0) = 60$

En base a esta ecuación se puede modelar como el crecimiento de un tumor está influenciado por la angiogénesis, el cual es el proceso de formación de nuevos vasos sanguíneos que nutren al tumor en sí. Es por esta razón que un sistema de ecuaciones diferenciales es utilizado para representar este fenómeno de crecimiento, ya que el crecimiento del tumor es en sí afectado por otra variable que cambia conforme el tiempo, la cual sería este soporte vascular. Por este motivo es que se escogió esta ecuación, ya que representa un SEDO dentro del campo de la medicina. Los valores de las constantes, $T(0)$, $E(0)$, k_g y k_1 se encontraron en la investigación original (Ouerdani, A., Struemper, H., Suttle, A. B., Ouellet, D., & Ribba, B. 2015) para que después fueran utilizados en nuestra modelación.

RK4

Para esta parte del trabajo realizamos dos métodos numéricos, uno con el método de Euler y otro con el de Runge-Kutta 4. Estos dos métodos se caracterizan por ser simples de implementar y por su habilidad de dar una solución aproximada con una alta precisión. La ecuación del método RK4 está dada por

$$y_{n+1} = y_n + \frac{1}{6} (k_1 + 2k_2 + 2k_3 + k_4)$$

Donde:

$$k_1 = h * f(t_n, y_n)$$

$$k_2 = h * f(t_n + \frac{h}{2}, y_n + \frac{k_1}{2})$$

$$k_3 = h * f(t_n + \frac{h}{2}, y_n + \frac{k_2}{2})$$

$$k_4 = h * f(t_n + h, y_n + k_3)$$

Se utilizó Python para ejecutar este método y generar las gráficas. Primero se inicializan los valores iniciales, declaración del intervalo de tiempo y el tamaño del paso. En este caso, se utiliza un For Loop para calcular de manera iterativa los valores de x y y para cada punto en

el tiempo. Para cada punto, calcula cada una de las k individuales, sumándose y actualizando el valor de x y y .

Euler

Para el método de Euler primero se definen los parámetros iniciales, tomando en cuenta un dt que representa el tamaño del paso del tiempo. Entre más pequeño se hace valor, resulta en una solución más precisa de las ecuaciones diferenciales. Este método tiene la forma:

$$y_{n+1} = y_n + f(t_n, y_n) * dt$$

De esta manera el método numérico aproxima la solución de la ecuación, lo cual hace sencillo su resolución mediante herramientas computacionales tales como Python o Matlab.

En nuestro caso, se elaboró en Python, utilizando un For Loop, que fuese llenando vectores en los cuales se guardaran los resultados, y así sucesivamente para la cantidad que se determine que sea el máximo valor al que se desea llegar.

Physics Informed Neural Network: PINN

Las redes neuronales físicamente informadas son un tipo de red neuronal que integra principios físicos, los cuales son representados por ecuaciones diferenciales. Al incorporar las leyes físicas en la función de pérdida, las PINNs guían el aprendizaje de la red hacia soluciones que respetan los comportamientos y restricciones reales del sistema. Consisten de 3 tipos de capas de neuronas, capas de entrada, capas ocultas, y capas de salida. Cada neurona tiene una función de activación que “prende” la neurona para que sea utilizada y genere una señal de salida dependiendo de la información de entrada. Las funciones más comúnmente utilizadas son la de sigmoide, la tangente hiperbólica, y la de Unidad Lineal Rectificada (ReLU). El entrenamiento de estas neuronas se hace con una función de costo específica para cada problema; en el caso de PINNs, se incluyen las ecuaciones diferenciales basadas en física dentro de esta función de pérdida para así poder modelar las ecuaciones. El objetivo es minimizar el resultado de esta función de costo para que así el modelo sea lo más similar a el modelo que estamos intentando simular dentro del set de entrenamiento.

Principales resultados gráficos y numéricos obtenidos

Se modela el tiempo en días aunque no esté explícitamente mencionado. Se usó el tiempo de 10 días, considerando que la investigación original (Ouerdani, 2015), se realizó en 25 días.

RK4




Figura 1: Gráficos de RK4

Estos fueron los resultados obtenidos de ambas gráficas respecto a la solución del sistema de ecuaciones. En la primera gráfica se demuestra cómo los tumores y las células endoteliales se comportan de una manera lineal positiva, indicando que en los primeros 10 días, el método de RK4 predice un crecimiento en ambos los tumores y las células endoteliales. Esto se ve de manera más directamente correlacionada en la segunda gráfica que muestra como hay una dependencia lineal positiva entre el número de tumores y el número de células endoteliales.

Euler Mejorado




Figura 2: Gráficos de Euler

En este método podemos observar como la pendiente de las células endoteliales es más alta que la de los tumores. Esto nos indica que tiene un crecimiento más rápido. Es importante notar que en otras iteraciones que se corrieron de este método con valores de tiempo mucho mayores, las gráficas tienen tendencia exponencial, lo cual es respaldado por la teoría y el sistema de ecuaciones diferenciales que se seleccionó. Ya que los tumores reciben nutrientes de estas células, el hecho que haya más de estas indica que el tumor puede empezar a crecer de manera exponencial mediante tiene acceso a más recursos para crecer.

Physics Informed Neural Network: PINN




Figura 3: Gráficos de PINN

En el primer gráfico, se puede observar como la función de pérdida de la red neuronal llega a la asíntota horizontal que se aproxima a cero en este tipo de soluciones; ejemplificando un

buen rendimiento del modelo. En el segundo gráfico generado mediante la red neuronal se observa cómo tanto los tumores como las células endoteliales tienen un crecimiento. Sin embargo este crecimiento, específicamente el de las células, se va reduciendo con el tiempo. Esto tiene varias posibles explicaciones biológicas, tal como la capacidad de soporte vascular. Esto nos explica como la angiogénesis, o la formación de nuevos vasos sanguíneos, tiene un límite en la capacidad de estos para soportar el crecimiento de un tumor. Este límite está determinado por la capacidad de proporcionar nutrientes y oxígeno al tumor, lo cual explica este comportamiento.

Resultados de comparativas: Gráficas y métricas

Primero, se observan las gráficas que comparan a los tres métodos. Se compara con los métodos numéricos porque se comprobó que el sistema de ecuaciones diferenciales original no podía ser resuelto analíticamente en herramientas computacionales (MathDF).




Figura 4: Gráficas Comparativas

Se observan los comportamientos de las gráficas. Estas mismas, se comparan a más detalle, en la parte de discusión y conclusión dentro de este reporte. No obstante, se observa que en el primero los tres son muy similares, y a partir de la segunda gráfica, se observa un comportamiento mucho más realista de parte de la PINN. Ahora, se observa las métricas que se consiguieron comparativas.

(Métricas)	RK4	Euler	PINN
max_growth_rate	0.22188	0.21932	0.28643
inflection_point	98	97	14
stability	4.03e-07	3.94e-07	3.91e-05

Figura 5: Tabla de métricas de métodos

Por fines de coherencia en el reporte, se abre una nueva sección para reportar las inferencias a base de estas inferencias y las gráficas anteriores.

Principales conclusiones

Se observan diferencias significativas en las trayectorias en las gráficas. En la primera gráfica, que analiza la trayectoria de la angiogénesis, los métodos RK4 y Euler muestran resultados idénticos al seguir una línea recta superpuesta, indicando que ambos tienen un comportamiento numérico equivalente en este aspecto. Por otro lado, PINN también sigue una trayectoria lineal, pero ligeramente por debajo, lo que sugiere una subestimación en el crecimiento angiogénico en comparación con los otros métodos.

En la segunda gráfica, que evalúa la evolución temporal de los tumores, los métodos RK4 y Euler presentan un crecimiento casi idéntico, con RK4 ligeramente más alto. En contraste, PINN muestra un comportamiento diferenciado, con un crecimiento inicial más fuerte que posteriormente converge hacia una estabilización alrededor de 21.5, lo que podría reflejar una dinámica más realista que incluye efectos de saturación biológica. Un patrón similar se observa en la tercera gráfica, donde se analiza la evolución de las células endoteliales. En este caso, PINN nuevamente presenta una estabilización, esta vez alrededor de 64.5, mientras que RK4 y Euler mantienen trayectorias prácticamente idénticas con un crecimiento lineal.

Las métricas respaldan estas observaciones. En términos de la tasa máxima de crecimiento, PINN tiene el valor más alto (0.2864), lo que indica que captura dinámicas iniciales más rápidas en comparación con RK4 (0.2219) y Euler (0.2193). Sin embargo, el punto de inflexión se alcanza mucho antes con PINN (14), en comparación con RK4 (98) y Euler (97), lo que resalta su capacidad para identificar cambios en las dinámicas más rápidamente. No obstante, en términos de estabilidad numérica, PINN es considerablemente menos estable ($3.91e-05$) que RK4 ($4.03e-07$) y Euler ($3.94e-07$), lo que puede ser una desventaja en sistemas que requieren alta precisión numérica.

Mejor método

En conclusión, la elección del mejor método depende de los objetivos del modelo. Si se prioriza la estabilidad y la precisión numérica, RK4 es la opción más adecuada, seguido de Euler. Sin embargo, si el objetivo es capturar comportamientos más realistas, como la saturación biológica, PINN es una mejor alternativa, aunque con sacrificios en estabilidad. Por lo tanto, la selección del método debe basarse en el balance entre realismo biológico y consistencia numérica.

Anexo

Notebook con los tres métodos y comparativa:

https://colab.research.google.com/drive/1eljIC_2ZUlt1Ioo-gV_v7trsTmNazzeS?usp=sharing

Bibliografía

IBM. (2024, 16 de mayo). *Neural networks*. Recuperado de <https://www.ibm.com/es-es/topics/neural-networks>

MathDF. *Calculator Ordinary Differential Equations (ODE) and Systems of ODEs*. <https://mathdf.com/dif/>

Iartificial. (2024, 11 de Julio). *Función de pérdida en el entrenamiento de una red neuronal*. Recuperado de <https://iartificial.blog/aprendizaje/funcion-de-perdida-en-el-entrenamiento-de-una-red-neuronal/>

Instituto Nacional del Cáncer. (2024, 9 de mayo). *Estadísticas del cáncer*. Recuperado de <https://www.cancer.gov/espanol/cancer/naturaleza/estadisticas>

Ouerdani, A., Struemper, H., Suttle, A. B., Ouellet, D., & Ribba, B. (2015). Preclinical Modeling of Tumor Growth and Angiogenesis Inhibition to Describe Pazopanib Clinical Effects in Renal Cell Carcinoma. *CPT: pharmacometrics & systems pharmacology*, 4(11), 660–668. <https://doi.org/10.1002/psp4.12001>

Yin, A., Moes, D. J. A. R., van Hasselt, J. G. C., Swen, J. J., & Guchelaar, H. J. (2019). A Review of Mathematical Models for Tumor Dynamics and Treatment Resistance Evolution of Solid Tumors. *CPT: pharmacometrics & systems pharmacology*, 8(10), 720–737. <https://doi.org/10.1002/psp4.12450>

Sociedad Española de Oncología Médica. (2019). *Angiogénesis*. Recuperado de <https://seom.org/43-Socios%20-%20Formaci%C3%B3n%20y%20Recursos/Bases%20de%20la%20Oncolog%C3%ADa/157-angiogenesis?showall=1&showall=1>